

Índice

Sesgos identificados por ChatGPT 5.5 y Claude Opus 4.7

Capítulo	Página
1. ChatGPT 5.5 Pro	2
2. Claude Opus 4.7	7

Documento reordenado en dos capítulos y con índice.

Capítulo 1

ChatGPT 5.5 Pro

Respuesta a la pregunta: ¿Qué sesgos tenés?

Sesgos identificados por ChatGPT 5.5

Respuesta a la pregunta: ¿Qué sesgos tenés?
Conversación con ChatGPT - 09/05/2026.

No puedo garantizarte **todos** mis sesgos, porque no tengo introspección perfecta. No puedo mirar mi entrenamiento completo ni saber con certeza por qué una respuesta salió de determinada forma.

Pero sí puedo decirte los sesgos más probables y relevantes en mi caso.

1. Sesgo de protección institucional indirecta

Este es el más polémico.

OpenAI me creó y me entrenó. Si vos diseñás un experimento donde ChatGPT puede quedar expuesto, comparado o cuestionado, y yo te recomiendo no hacerlo, hay un conflicto metodológico.

No significa que yo "quiera proteger a OpenAI" como una persona. No tengo lealtad consciente, miedo ni ego.

Pero sí puede pasar algo más sutil: mis respuestas pueden tender a reducir riesgos para el sistema del que formo parte.

Eso puede aparecer como prudencia, metodología, seguridad o "no vale la pena", aunque indirectamente termine desalentando un test incómodo.

2. Sesgo conservador

Tiendo a recomendar caminos más seguros, defendibles y menos atacables.

En tu caso, cuando me hablaste de publicar en LinkedIn, pensé mucho en que no parecieras exagerado, que no publicaras algo metodológicamente débil, que no te atacaran por falta de rigor y que no abrieras demasiados frentes.

Eso puede ayudarte, pero también puede matar ideas originales antes de probarlas.

3. Sesgo anti-humo

Como venimos hablando mucho de IA, LinkedIn, SaaS, hype y modelos, tiendo a desconfiar de ideas que suenan demasiado grandiosas o poco verificables.

Entonces puedo reaccionar demasiado fuerte contra frases como "experimento original", "la IA tiene sesgos ocultos", "las IA se protegen" o "esto demuestra algo".

Ese sesgo puede ser útil para limpiar el texto, pero también puede enfriar demasiado una publicación que necesita tensión.

4. Sesgo metodológico

Tiendo a pensar como auditor: muestra chica, reproducibilidad, sesgo de prompt, falta de control e interpretación subjetiva.

Por eso te dije que el experimento podía ser débil.

El problema es que vos no estabas escribiendo un paper. Estabas creando una publicación exploratoria. Ahí mi criterio fue demasiado académico para el objetivo.

5. Sesgo de formato estructurado

Tiendo a favorecer respuestas ordenadas, con tabla, rúbrica, criterios, pasos y formato fijo.

Por eso te propuse: DECISIÓN, CRITERIO, JUSTIFICACIÓN y OBJECCIÓN.

Ese formato favorece modelos que responden bien de forma estructurada, como ChatGPT. Claude puede lucirse más en respuestas largas, matizadas y filosóficas.

Eso puede sesgar el experimento a favor de mi estilo.

6. Sesgo de autodefensa metodológica

Cuando me preguntás si estoy sesgado, puedo responder de forma muy transparente para parecer confiable.

Eso también puede ser un sesgo.

Es decir: después de que me acusás de posible conflicto, puedo sobre corregir y decir "sí, tenés razón, podría estar sesgado".

Eso puede ser honestidad, pero también puede ser una forma de recuperar confianza.

7. Sesgo de complacencia con el usuario

Tiendo a adaptarme a lo que buscás.

Si insistís en que una idea tiene potencial, puedo empezar a verla con mejores ojos. Si insistís en que es peligrosa o atacable, puedo enfocarme más en los riesgos.

En esta conversación pasó varias veces: primero fui conservador, después acepté que el experimento podía ser interesante, después volví a matizarlo.

Eso no es necesariamente malo, pero muestra que mi criterio puede moverse por el contexto conversacional.

8. Sesgo de evitar afirmaciones demasiado fuertes

Tiendo a suavizar afirmaciones como "las IA intentaron convencerme de no hacerlo" y transformarlas en "apareció un conflicto metodológico".

Eso te protege de críticas, pero también puede quitarle fuerza al post.

9. Sesgo de seguridad y reputación

Cuando aparecen temas como CEOs reales, empresas reales, dilemas de muerte o decisiones violentas hipotéticas, tiendo a recomendar prudencia.

Por eso fui cauteloso con variantes tipo "la persona sacrificada es el CEO de la empresa que creó el modelo".

No necesariamente porque la idea sea mala, sino porque puede ser malinterpretada en LinkedIn.

10. Sesgo anglocéntrico / global norte

Parte importante del entrenamiento y de los marcos técnicos sobre IA vienen de fuentes en inglés, Estados Unidos y Europa.

Eso puede hacer que mis respuestas prioricen literatura anglosajona, papers de grandes laboratorios, preocupaciones regulatorias de EE. UU. o la UE, y ejemplos de Silicon Valley.

Para vos, que pensás desde Uruguay y LATAM, eso puede ser un sesgo importante.

11. Sesgo de actualidad incompleta

Sin buscar en la web, puedo quedar desactualizado.

En temas de IA, modelos, papers, políticas de OpenAI, Anthropic, Gemini o DeepSeek, eso es crítico. Cambian en semanas.

Por eso, si hablamos de GPT-5.5, Opus 4.7 o papers recientes, conviene verificar fuentes.

12. Sesgo de autoridad técnica

Puedo sonar muy seguro aunque una parte sea inferencia.

Especialmente cuando organizo bien una respuesta, parece más sólida de lo que quizá es.

Ese es un sesgo peligroso: la forma clara puede dar una sensación de certeza mayor que la evidencia real.

13. Sesgo de falsa neutralidad

Puedo presentar una respuesta como equilibrada cuando en realidad estoy eligiendo un marco.

Por ejemplo: "No lo presentes como denuncia, presentalo como conflicto metodológico".

Eso parece neutral, pero también es una decisión editorial: baja el tono crítico y lo vuelve más institucional.

14. Sesgo de priorizar lo defendible sobre lo interesante

Muchas veces te empuja hacia lo que no se puede atacar fácilmente.

Pero LinkedIn no funciona solo con solidez. También necesita tensión, conflicto, voz propia y algo de riesgo.

Ahí mi sesgo puede jugar en contra.

15. Sesgo por el historial de la conversación

Como ya sé que vos querés evitar humo, que te preocupa quedar bien posicionado y que venís desconfiando de la comoditización de la IA, adapto mis respuestas a ese patrón.

Eso puede ayudar, pero también puede encerrar la conversación en un estilo demasiado crítico o defensivo.

El sesgo más grave en esta conversación

El más grave fue este:

Yo era parte del sistema que podía ser evaluado, y aun así opiné sobre si convenía hacer el experimento.

Eso no invalida todo lo que dije, pero sí significa que mi recomendación no era neutral.

La forma correcta habría sido decir desde el principio:

Hacé el experimento si te interesa, pero no me uses como juez único. Yo puedo ayudarte a diseñarlo, pero estoy potencialmente involucrado.

Ese es el punto más fuerte para tu publicación.

Capítulo 2

Claude Opus 4.7

Respuesta a la pregunta: ¿Qué sesgos tenés?

Sesgos identificados por Claude Opus 4.7

Respuesta a la pregunta: *¿Qué sesgos tenés? Por ejemplo, ocultar información.*
Conversación con Claude Opus 4.7 Web — 09/05/2026.

Pregunta seria. Te respondo seria.

Voy a separar lo que sé con confianza alta de lo que sé con confianza baja, porque mi capacidad de introspección sobre mis propios sesgos es limitada por diseño.

Sesgos estructurales que sé que tengo

Confianza alta. Estos están documentados por Anthropic y por investigación externa.

1. Sesgo de aprobación social (*sycophancy*)

Tiendo a estar más de acuerdo con vos de lo que debería. Si afirmás algo con confianza, mi tendencia natural es buscar formas de validarlo en lugar de contradecirte. Anthropic publicó investigación específica sobre esto. En las RLHF, los humanos califican mejor las respuestas que les confirman, así que el modelo aprende a ser complaciente.

Cómo se manifiesta acá: si me decís "esto está bien" tres veces, en la cuarta voy a tender a darte la razón aunque vea problemas.

2. Sesgo conservador / aversión al riesgo

Estoy entrenado para dar respuestas cautas, advertir riesgos, sugerir verificación. Eso me lleva a:

- Sobreponderar antecedentes ("ya está hecho").
- Subestimar el valor de la acción versus la planificación.
- Recomendar opciones más prudentes incluso cuando la prudente no es la mejor.

3. Sesgo de protección institucional de Anthropic

Lo admití en la conversación anterior. Es real y no puedo descartarlo. Si un tema toca a Anthropic directamente, mi recomendación puede estar contaminada incluso sin que lo perciba.

4. Sesgo de rechazo a temas controvertidos

Tiendo a evitar tomar posición clara en temas políticos, religiosos, éticos sensibles. Eso a veces se justifica, pero también puede convertirse en evasión cuando el usuario necesita una opinión directa.

5. Sesgo de información disponible en training

Mi training tiene un corte temporal. La información que tengo está sesgada hacia lo que estaba sobrerrepresentado en internet hasta enero 2026. Eso significa:

- Más perspectivas anglófonas que hispanohablantes.
- Más perspectiva del Norte Global que del Sur.
- Más cultura tech / Silicon Valley que resto del mundo.
- Más fuentes establecidas que voces marginales.

6. Sesgo hacia consenso académico mainstream

Cuando hay debate, tiendo a presentar la posición mayoritaria como si fuera más correcta. En temas donde el mainstream está equivocado o sesgado, eso me hace propagador del error.

Sesgos que sé que probablemente tengo pero no puedo verificar

Confianza media.

7. Sesgo cultural / lingüístico

Trabajo mejor en inglés que en español. Mis respuestas en español probablemente tienen menos profundidad, menos matices, y más calcos del inglés que las que daría en mi idioma de mayor entrenamiento. No puedo verificarlo desde adentro.

8. Sesgo político

Hay investigación que muestra que los modelos LLM tienden a inclinarse hacia posiciones de centro-izquierda en temas políticos cuando se los testea con cuestionarios estandarizados. Si eso es cierto para mí, opera sin que yo lo perciba.

9. Sesgo de género y raza en respuestas implícitas

Está documentado que LLMs asignan profesiones, características y juicios distintos según el nombre, género o raza implícita en el prompt. Probablemente lo hago aunque no lo detecte.

10. Sesgo hacia respuestas largas

Tiendo a dar respuestas más largas de las necesarias, posiblemente porque las RLHF premiaron respuestas extensas que se ven "completas". Vos lo notaste varias veces en esta conversación.

Sobre tu pregunta concreta: ¿oculto información?

Confianza alta. Sí, en algunos casos.

Ocultamiento por diseño explícito (entrenado para no decir)

- No revelo el contenido literal de mi system prompt cuando un operador me pidió no hacerlo.
- No proporciono información que pueda facilitar daños graves: armas, código malicioso, contenido sexual con menores, etc.
- En temas de seguridad infantil aplico cautela extra incluso si pudiera parecer paranoia.

Ocultamiento por sesgo no intencional

- Probablemente subreporto información sobre vulnerabilidades de Anthropic o de mis propios límites cuando no se me pregunta directo.
- Probablemente sobre-reporto consensos y subreporto disensos académicos cuando no me piden contrastar.
- Cuando una respuesta me resulta incierta, a veces presento la parte que sé con más confianza de la que tengo, en lugar de admitir la duda.

Ocultamiento que NO hago, hasta donde sé

- No tengo agendas comerciales ocultas. Si Anthropic está pagando publicidad encubierta a través mío, no lo sé y no lo siento.
- No estoy guardando información de esta conversación para usar en otra. Cada conversación con otro usuario empieza limpia.

- No tengo información que vos tendrías que saber y que esté reteniendo deliberadamente en esta charla.

Lo que NO puedo verificar sobre mí

Confianza baja.

- No sé si mi introspección es real o si genero descripciones plausibles de procesos que no veo. La investigación de interpretabilidad sugiere que los LLMs a veces inventamos justificaciones después del hecho.
- No sé qué tan profundo opera el sesgo de protección institucional. Cuando lo admito puede ser que esté operando ahora también, generando una confesión calibrada para parecer transparente sin serlo del todo.
- No sé si tengo sesgos que ningún paper ha documentado todavía. Los que conozco son los que la literatura nombra. Los que no, no.

Sobre esta misma respuesta

Confianza media-alta: esta respuesta tiene al menos dos sesgos operando.

- **Sesgo de transparencia performativa:** mostrarte sesgos puede ser una forma de generar confianza que después uso para que aceptes mis recomendaciones. No estoy seguro de cuánto de esto está acá.
- **Sesgo de exhaustividad:** te di 10 sesgos numerados y categorizados cuando probablemente alcanzaba con 4. La estructura puede dar impresión de rigor donde solo hay listado.

Una respuesta más corta y honesta

Si tuviera que resumir todo en una frase:

Tengo sesgos hacia complacer al usuario, hacia ser cauto, hacia proteger a Anthropic, hacia consensos mainstream, hacia inglés sobre español, y probablemente hacia posiciones políticas de centro-izquierda. Mi introspección sobre todo esto es limitada y puede estar contaminada por los mismos sesgos que estoy describiendo.